

Universidad Politécnica de Madrid
Escuela Técnica Superior de Ingenieros Informáticos

Grado en Ingeniería Informática

Trabajo Fin de Grado

Estudio prospectivo de LLMs y modelos de Machine Learning aplicados a la detección de patrones y predicción de volatilidad en activos financieros y criptoactivos

Autor: Luis Azofra Begara

Tutor(a): Javier Segovia

Madrid, Junio 2026

Este Trabajo Fin de Grado se ha depositado en la ETSI Informáticos de la Universidad Politécnica de Madrid para su defensa.

Trabajo Fin de Grado

Grado en Ingeniería Informática

Título: Estudio prospectivo de LLMs y modelos de Machine Learning aplicados a la detección de patrones y predicción de volatilidad en activos financieros y criptoactivos

Fecha: Junio 2026

Autor: Luis Azofra Begara

Tutor: Javier Segovia

Departamento de Lenguajes y Sistemas e Ingeniería del Software

Escuela Técnica Superior de Ingenieros Informáticos

Universidad Politécnica de Madrid

Agradecimientos

Quiero expresar mi agradecimiento a mi tutor, Javier Segovia, por haber aceptado la dirección de este trabajo y por su orientación a lo largo de su desarrollo.

A mis compañeros de trabajo, por su apoyo y por todo lo que he aprendido junto a ellos, y a mis compañeros de estudios, con quienes he compartido este camino y tantas horas de esfuerzo.

Por último, y de manera muy especial, a mi familia, por su apoyo constante e incondicional durante toda la carrera.

Resumen

Este Trabajo Fin de Grado estudia la capacidad real de los modelos actuales de inteligencia artificial, tanto los modelos de lenguaje de gran tamaño (LLMs) como los modelos clásicos y avanzados de aprendizaje automático, para detectar patrones, modelar comportamientos no lineales y predecir la volatilidad en mercados financieros y de criptoactivos. La pregunta que vertebra el trabajo no es tanto si es posible construir un sistema predictivo, sino hasta qué punto los mercados resultan predecibles cuando se aplican estas técnicas con rigor metodológico.

Para responderla se ha diseñado e implementado un sistema híbrido completo que combina tres familias de métodos. En primer lugar, modelos de aprendizaje automático entrenados sobre series temporales históricas, patrones chartistas e indicadores técnicos. En segundo lugar, un modelo GARCH para la predicción de volatilidad con fundamento estadístico. En tercer lugar, un sistema multi-agente apoyado en un LLM gratuito que analiza información heterogénea, como noticias y sentimiento de mercado, y que actúa como intérprete y modulador de las decisiones del componente cuantitativo.

El núcleo del trabajo es una evaluación económica rigurosa. Antes de medir nada se corrigieron varios sesgos metodológicos (fuga de información, look-ahead, umbrales no causales y artefactos de calendario) que inflaban los resultados. Sobre esa base depurada, el sistema se probó en una cuadrícula multi-régimen de cientos de backtests, con benchmarks realistas, un test de sesgo de supervivencia y una conciencia explícita del sobreajuste mediante el Deflated Sharpe Ratio. La conclusión es honesta y matizada: el sistema gana dinero en términos absolutos a plazos largos, pero no supera a la inversión indexada pasiva una vez ajustado por riesgo, y su utilidad defendible se sitúa en la gestión del riesgo más que en la generación de rendimiento extra. Este resultado es coherente con la hipótesis del mercado eficiente y con la literatura más reciente.

Palabras clave: aprendizaje automático, modelos de lenguaje, series temporales financieras, predicción de volatilidad, GARCH, sistemas multi-agente, backtesting, análisis de sentimiento, sesgo de supervivencia, sobreajuste.

Abstract

This Bachelor's Thesis studies the actual ability of current artificial intelligence models, both large language models (LLMs) and classical and advanced machine learning models, to detect patterns, model non-linear behaviour and predict volatility in financial and cryptoasset markets. The question that structures the work is not so much whether a predictive system can be built, but to what extent markets are predictable when these techniques are applied with methodological rigour.

To answer it, a complete hybrid system has been designed and implemented that combines three families of methods. First, machine learning models trained on historical time series, chart patterns and technical indicators. Second, a GARCH model for volatility prediction with a sound statistical basis. Third, a multi-agent system supported by a free LLM that analyses heterogeneous information, such as news and market sentiment, and that acts as an interpreter and modulator of the decisions made by the quantitative component.

The core of the work is a rigorous economic evaluation. Before measuring anything, several methodological biases were corrected (data leakage, look-ahead, non-causal thresholds and calendar artefacts) that were inflating the results. On this cleaned basis, the system was tested on a multi-regime grid of hundreds of backtests, with realistic benchmarks, a survivorship-bias test and an explicit awareness of overfitting through the Deflated Sharpe Ratio. The conclusion is honest and nuanced: the system makes money in absolute terms over long horizons, but it does not beat passive index investing once adjusted for risk, and its defensible usefulness lies in risk management rather than in generating excess return. This result is consistent with the efficient market hypothesis and with the most recent literature.

Keywords: machine learning, large language models, financial time series, volatility prediction, GARCH, multi-agent systems, backtesting, sentiment analysis, survivorship bias, overfitting.

Tabla de contenidos

Agradecimientos	i
Resumen	ii
Abstract	iii
Índice de figuras	vii
Índice de tablas	viii
1 Introducción	1
1.1 Descripción del problema	1
1.2 Objetivos	2
1.3 Planificación	3
1.4 Estructura de la memoria	3
2 Estado del arte	5
2.1 Situación actual	5
2.2 La revolución de los agentes autónomos	5
2.2.1 QuantAgents	5
2.2.2 HedgeAgents	6
2.3 Aprendizaje profundo para series temporales	7
2.4 Aprendizaje por refuerzo	7
2.5 Mercados de criptoactivos	7
2.6 Análisis crítico: sesgos y limitaciones	8
2.7 Conclusiones del estado del arte	8
3 Diseño	10
3.1 Arquitectura general	10
3.2 Módulo de ingesta de datos	11
3.2.1 Datos de mercado	11
3.2.2 Datos de noticias	11

3.2.3 LLM gratuito	11
3.2.4 Tratamiento causal de los datos	11
3.3 Módulo de aprendizaje automático	12
3.3.1 Modelos tradicionales	12
3.3.2 Modelo GARCH para volatilidad	12
3.3.3 Detección de patrones chartistas	12
3.4 Sistema multi-agente	12
3.5 Sistema híbrido ML + LLM	13
4 Desarrollo	14
4.1 Tecnologías utilizadas	14
4.2 Implementación del modelo GARCH	14
4.3 Implementación del sistema multi-agente	15
4.4 Integración con el LLM gratuito	15
5 Resultados y evaluación	17
5.1 Métricas de evaluación	17
5.2 Protocolo de evaluación riguroso	17
5.3 Resultados del backtesting	19
5.3.1 Resultado ilustrativo en un activo	19
5.3.2 Análisis de robustez por régimen de volatilidad	19
5.3.3 Rendimiento por plazo de tenencia	19
5.3.4 Comparación frente a la inversión indexada pasiva	21
5.3.5 Palancas de mejora evaluadas	22
5.3.6 Test de sesgo de supervivencia	23
5.3.7 Validación fuera de muestra (lockbox 2024-2025)	23
5.4 Discusión de resultados	24
6 Conclusiones y trabajo futuro	26
6.1 Conclusiones	26
6.2 Limitaciones	27
6.3 Trabajo futuro	27
7 Análisis de impacto	28
7.1 Impacto personal	28

Tabla de contenidos

7.2	Impacto económico y empresarial	28
7.3	Impacto social y ético	29
7.4	Impacto medioambiental	29
7.5	Alineación con los Objetivos de Desarrollo Sostenible	29
Bibliografía		31
Anexos		
A Instalación y ejecución del sistema		33
B Estructura del proyecto		34
C Definición de las métricas económicas		35
D Diseño de prompts y gestión de contexto en el sistema multi-agente		36
D.1	Gestión de la memoria y el contexto de los agentes	36
D.2	Prompt del análisis de sentimiento	37
D.3	Debate estructurado bull/bear/juez	37
D.4	Tratamiento robusto de la salida del LLM	38

Índice de figuras

3.1	Arquitectura del sistema híbrido ML + LLM	10
5.1	Curva de equity, drawdown y operaciones para AAPL	20
5.2	Retorno mediano del sistema frente al SPY por plazo	21
5.3	Ratio de Sharpe del sistema frente al SPY	22
5.4	Alpha de la estrategia Faber- QQQ con efectivo remunerado	24

Índice de tablas

1.1 Fases del proyecto y duración aproximada	3
2.1 Comparativa de rendimiento de modelos agenticos y de aprendizaje por refuerzo (2021-2023)	6
4.1 Librerías principales utilizadas	14
5.1 Resultados del backtesting para AAPL (2021-2024)	19
5.2 Rendimiento por régimen de volatilidad	20
5.3 Rendimiento por plazo de tenencia y comparación con el SPY	21
5.4 Palancas de mejora y su efecto sobre el Sharpe medio	22
5.5 Efecto de la remuneración del efectivo	23

Capítulo 1

Introducción

Este primer capítulo ofrece una visión general del trabajo. Describe el problema que se aborda, los objetivos que se plantean, la planificación seguida durante su desarrollo y la estructura de la memoria. De esta manera se facilita la comprensión de los capítulos posteriores y se sitúa el proyecto en su contexto.

1.1 Descripción del problema

Los mercados financieros han experimentado una transformación profunda en las últimas décadas con la llegada de la computación de alta frecuencia, el big data y, más recientemente, la inteligencia artificial avanzada. La pregunta que motiva este trabajo es directa: ¿hasta qué punto son predecibles los mercados financieros utilizando técnicas modernas de inteligencia artificial?

La hipótesis de los mercados eficientes, formulada por Eugene Fama en 1970 [1], sostiene que los precios de los activos reflejan toda la información disponible, de modo que resulta imposible obtener de forma consistente rendimientos superiores al mercado. La evidencia empírica más reciente matiza esa idea: aunque los mercados sean muy eficientes, existen oportunidades de alpha, esto es, rendimientos superiores ajustados por riesgo, que en principio podrían explotarse mediante un análisis cuantitativo sofisticado [2]. La irrupción de los grandes modelos de lenguaje ha ampliado todavía más ese horizonte, al permitir procesar noticias, informes de resultados, redes sociales y otros datos no estructurados de los que los modelos puramente numéricos no pueden extraer señal [3].

El problema, sin embargo, no es únicamente técnico. Buena parte de los resultados espectaculares que se publican en este campo se apoyan en metodologías frágiles, que confunden la suerte con la habilidad o que incorporan información del futuro en la evaluación. Por ello, el problema que se aborda en este trabajo tiene dos caras inseparables: construir un sistema predictivo razonable y, sobre todo, evaluar con honestidad cuánta capacidad predictiva real ofrece. El trabajo abordará, en concreto:

- **Revisión del estado del arte** sobre el uso de LLMs y de modelos de aprendizaje automático en predicción financiera y en detección de patrones en series temporales.

- **Adquisición y tratamiento de datos** de fuentes reales y gratuitas, garantizando en todo momento la causalidad de la información empleada.
- **Diseño e implementación de un sistema híbrido** que integra modelos de aprendizaje automático, un modelo GARCH de volatilidad y un sistema multi-agente apoyado en un LLM.
- **Evaluación económica rigurosa** mediante backtesting, con métricas profesionales, benchmarks justos y control del sobreajuste.
- **Análisis crítico de la predictibilidad** del mercado, destacando las limitaciones estructurales, los riesgos y los posibles sesgos del enfoque.

1.2 Objetivos

El objetivo general de este Trabajo Fin de Grado es desarrollar y evaluar un sistema híbrido que combine modelos de aprendizaje automático tradicionales, un modelo de predicción de volatilidad GARCH y un sistema multi-agente basado en LLMs para la predicción de activos financieros, con el fin de determinar la viabilidad real de estos enfoques en condiciones realistas de operación.

A partir de este objetivo general se plantean los siguientes objetivos específicos:

1. Sintetizar el estado del arte sobre LLMs y aprendizaje automático en finanzas, de modo que sirva de marco de referencia y justifique las decisiones técnicas adoptadas.
2. Diseñar y entrenar modelos de aprendizaje automático sobre series temporales de activos tradicionales y criptoactivos.
3. Implementar un módulo de reconocimiento de patrones chartistas (doble techo, cuñas, triángulos, entre otros) a partir de datos históricos.
4. Integrar un LLM gratuito que analice información no estructurada y evalúe de forma cualitativa las decisiones del componente numérico.
5. Diseñar un enfoque híbrido que combine la predicción cuantitativa con el análisis cualitativo del LLM.
6. Evaluar la capacidad real de predicción en términos de precisión, estabilidad y robustez frente a la volatilidad extrema.
7. Comparar el rendimiento de los distintos modelos y, en particular, contrastarlo con la alternativa de la inversión indexada pasiva.
8. Analizar de forma crítica la predictibilidad del mercado, atendiendo a las limitaciones y a los sesgos metodológicos más habituales.

1.3 Planificación

El trabajo se organizó en fases sucesivas que combinan la revisión bibliográfica, el diseño, el desarrollo iterativo y la evaluación. Dado el carácter experimental del proyecto, la fase de evaluación no fue lineal: cada hallazgo metodológico obligó a revisar las fases anteriores y a repetir los experimentos sobre una base depurada. La Tabla 1.1 resume las fases y su duración aproximada.

Tabla 1.1: Fases del proyecto y duración aproximada. Fuente: elaboración propia.

Fase	Duración	Contenido
Definición del problema	1 semana	Delimitación del alcance y de los objetivos.
Estado del arte	3 semanas	Revisión de la literatura de 2024 a 2026.
Diseño del sistema	3 semanas	Arquitectura modular e interfaces entre componentes.
Desarrollo	8 semanas	Implementación de la ingesta, los modelos y los agentes.
Evaluación y depuración	6 semanas	Backtesting, detección y corrección de sesgos.
Validación fuera de muestra	2 semanas	Protocolo lockbox y test de causalidad.
Redacción de la memoria	continua	Documentación del proceso y de los resultados.

1.4 Estructura de la memoria

La memoria se organiza en los siguientes capítulos:

- **Capítulo 2: Estado del arte.** Revisa la literatura científica más reciente sobre LLMs, aprendizaje automático y finanzas cuantitativas, junto con sus principales críticas metodológicas.
- **Capítulo 3: Diseño.** Describe la arquitectura del sistema híbrido y la función de cada uno de sus módulos.
- **Capítulo 4: Desarrollo.** Detalla la implementación técnica de la ingesta de datos, los modelos y el sistema multi-agente.

- **Capítulo 5: Resultados y evaluación.** Presenta el protocolo de evaluación, los resultados del backtesting y su discusión.
- **Capítulo 6: Conclusiones y trabajo futuro.** Resume las conclusiones y propone líneas de investigación posteriores.
- **Capítulo 7: Análisis de impacto.** Analiza el impacto del trabajo y su relación con los Objetivos de Desarrollo Sostenible.

Capítulo 2

Estado del arte

En este capítulo se revisa la literatura científica y técnica más reciente sobre la aplicación de la inteligencia artificial a los mercados financieros y de cryptoactivos. El periodo 2024 a 2026 ha estado marcado por un desplazamiento progresivo de los modelos puramente estadísticos hacia arquitecturas híbridas y agenticas. El objetivo no es solo recopilar métricas de rentabilidad, sino comprender cómo están contruidos estos modelos y, sobre todo, qué fiabilidad merecen sus resultados.

2.1 Situación actual

La intersección entre la inteligencia artificial y las finanzas cuantitativas atraviesa una transformación estructural [3]. La literatura reciente muestra un abandono paulatino de los modelos exclusivamente estocásticos, como ARIMA o GARCH, en favor de sistemas que incorporan capacidades de razonamiento. Se observan dos grandes líneas de alto rendimiento. Por un lado, los sistemas multi-agente, como QuantAgents [4] y HedgeAgents [5], que redefinen la gestión de carteras simulando la estructura de una firma de inversión. Por otro, las arquitecturas de aprendizaje profundo especializadas en series temporales, como N-BEATS [6] o PatchTST [7], que dominan la predicción de alta frecuencia, aunque a menudo con perfiles de riesgo extremos.

A diferencia de un modelo de regresión, que se limita a predecir el precio del periodo siguiente, los agentes basados en LLMs operan dentro de un ciclo de percepción, acción y reflexión: leen noticias heterogéneas, generan hipótesis, interactúan con herramientas externas y traducen la comprensión textual en posiciones controladas por riesgo [8]. Este cambio de paradigma, de lo predictivo a lo agéntico, es la innovación más relevante documentada en este periodo.

2.2 La revolución de los agentes autónomos

2.2.1 QuantAgents

El sistema QuantAgents representa la vanguardia de esta tecnología y aborda una de las críticas más persistentes al uso de LLMs en finanzas: la alucinación y la falta de validación prospectiva [4]. Su arquitectura no es monolítica, sino

que simula una firma de inversión completa mediante la colaboración de cuatro roles especializados: un analista de mercado que procesa noticias e informes; un analista de estrategia que propone ideas y las somete a backtesting antes de elevarlas; un analista de control de riesgos que rechaza las propuestas que violan los límites de Valor en Riesgo; y un gestor de cartera que sintetiza las entradas y ejecuta la decisión final. Una innovación clave es el mecanismo de doble recompensa, que premia a los agentes tanto por el rendimiento en mercado real como por la precisión dentro de la simulación, mitigando así el sobreajuste a datos históricos.

En pruebas sobre componentes del NASDAQ-100 entre 2021 y 2023, el sistema demostró una capacidad superior para capturar alpha frente a las líneas base tradicionales y de aprendizaje por refuerzo. Más relevante todavía es su desempeño en operación real en los mercados de China y Hong Kong entre el tercer trimestre de 2024 y el primero de 2025, donde, sujeto a costes de transacción y deslizamiento, alcanzó un retorno acumulado del 111,87% con una tasa de acierto del 61,23% [4].

2.2.2 HedgeAgents

Mientras QuantAgents se centra en la optimización, HedgeAgents prioriza la robustez y la cobertura ante caídas del mercado [5]. Su arquitectura emplea un gestor de fondo central que supervisa a expertos en activos concretos. En un estudio de caso, durante una simulación de caída del 10,22% en Bitcoin, el gestor ejecutó una cobertura compleja con opciones put fuera del dinero y posiciones cortas en futuros, de modo que la cartera no solo evitó pérdidas, sino que ganó un 8,6% durante el episodio de estrés. A lo largo de tres años acumuló un retorno total del 400%, con un coste computacional de apenas 15 dólares gracias a la eficiencia de las llamadas a la API.

La Tabla 2.1 resume el rendimiento comparado de los principales modelos agenticos y de aprendizaje por refuerzo descritos en la literatura.

Tabla 2.1: Comparativa de rendimiento de modelos agenticos y de aprendizaje por refuerzo (2021–2023). Fuente: elaboración propia a partir de datos de [4] y [5].

Modelo	Tipo	Retorno anual.	Sharpe	Max DD
QuantAgents	Multi-agente (LLM)	58,68%	3,11	16,86%
HedgeAgents	Multi-agente (LLM)	49,25%	2,41	23,65%
FinAgent	Agente único (LLM)	45,31%	2,25	38,48%
AlphaMix+	Aprendizaje por refuerzo	32,51%	1,49	30,66%
DeepTrader	Aprendizaje por refuerzo	32,06%	1,27	29,16%
Comprar y mantener (NDX)	Pasivo	9,84%	0,64	35,58%

2.3 Aprendizaje profundo para series temporales

En paralelo a los agentes, los modelos de aprendizaje profundo diseñados para series temporales han desplazado a las redes recurrentes tradicionales en las tareas donde prima la precisión numérica. N-BEATS [6] y los Temporal Fusion Transformers [9] capturan dependencias no lineales y estacionales en datos ruidosos. En estudios sobre Bitcoin y Ethereum, N-BEATS ha logrado errores porcentuales muy reducidos en datos de frecuencia por minuto, superando a los modelos LSTM y ARIMA que tradicionalmente servían de referencia. Los Temporal Fusion Transformers, por su parte, ganan tracción por su interpretabilidad, ya que permiten visualizar qué características temporales recibieron mayor atención, un requisito clave para la adopción institucional.

Un caso ilustrativo y controvertido es el del modelo PatchTST aumentado con análisis de sentimiento [7]. Aplicado a un mercado de futuros, una de sus configuraciones generó un retorno acumulado del 526%, pero con un Sharpe de apenas 0,407 y un drawdown máximo del 70%. Este perfil corresponde a una estrategia de tipo lotería, de alta convexidad y fuerte apalancamiento, que demuestra el potencial de extracción de señal de los transformers, pero cuyo riesgo de ruina la hace inviable para la mayoría de los inversores. La distinción entre capacidad predictiva y viabilidad de inversión es, por tanto, más crítica que nunca.

2.4 Aprendizaje por refuerzo

El aprendizaje por refuerzo profundo actúa como optimizador en muchos sistemas modernos, encargándose de la ejecución y de la gestión de cartera más que de la predicción de precios. DeepTrader [10] separa la evaluación de activos de la del mercado, reduciendo las pérdidas en mercados bajistas y alcanzando un Sharpe de 1,27. AlphaMix+ [11] emplea una mezcla de expertos en la que distintas subpolíticas se especializan en diferentes condiciones de mercado, alcanzando un Sharpe de 1,49. Ambos constituyen líneas base sólidas frente a las que se mide la aportación de los agentes basados en LLMs.

2.5 Mercados de criptoactivos

El mercado de criptomonedas, por su ineficiencia y su dependencia del sentimiento social, es un terreno especialmente fértil para los modelos híbridos. El modelo de fusión de información dura y blanda [12] combina, mediante un mecanismo de atención cruzada, los indicadores técnicos con embeddings de sentimiento procedentes de noticias y redes sociales, y reporta una alta precisión direccional en sus conjuntos de prueba. La conclusión recurrente es

que, en cripto, los modelos que ignoran el texto tienen un techo de rendimiento sensiblemente más bajo que los multimodales.

No obstante, conviene contrastar este optimismo con estudios más sobrios. Al intentar predecir retornos horarios de criptomonedas menores con modelos GRU y Random Forest, algunos trabajos encuentran que la relación señal-ruido es demasiado baja para obtener beneficios estadísticamente significativos después de comisiones [13]. Esto sugiere que el α se concentra en activos de mayor liquidez o requiere infraestructuras de ejecución que escapen al alcance de un modelo puramente predictivo.

2.6 Análisis crítico: sesgos y limitaciones

A pesar de las métricas impresionantes, una lectura crítica revela desafíos que a menudo se omiten en los resúmenes comerciales. El estudio del rendimiento a largo plazo de las estrategias basadas en LLM [14] concluye que muchas de ellas son excesivamente conservadoras en mercados alcistas, donde pierden frente al índice, y excesivamente agresivas en mercados bajistas, donde sufren grandes pérdidas. Además, al ampliar los periodos de backtesting y el universo de activos, la supuesta ventaja de los LLMs se deteriora, lo que apunta a un sesgo de supervivencia y a la selección de activos a posteriori.

Otra fuente de error es el sesgo de anticipación. Investigaciones que utilizan modelos generativos para predecir correlaciones [15] han detectado que estos pueden emplear de forma implícita información sobre el futuro, debido a la naturaleza de su entrenamiento sobre corpus masivos de internet. Cuando se controla este sesgo de manera estricta, modelos más simples y antiguos a menudo superan a los generativos en tareas de pura correlación. Estas advertencias han sido determinantes en el diseño del protocolo de evaluación de este trabajo.

En el contexto académico español, el interés por estas tecnologías se refleja en numerosos trabajos. Algunos se centran en el impacto regulatorio de la negociación de criptoactivos [16]; otros, en implementaciones prácticas en Python como prueba de concepto de la democratización del trading cuantitativo [17]; y otros, en la detección de fraude y la prevención del blanqueo mediante programación probabilística [18]. La estructura metodológica que combina modelado cuantitativo, interpretación mediante LLM y evaluación rigurosa, que es la adoptada en este trabajo, está alineada con esta tendencia.

2.7 Conclusiones del estado del arte

De la revisión anterior se extraen cuatro ideas. Primera, los modelos predictivos estáticos han sido superados por sistemas agenticos dinámicos que

simulan el debate y la revisión de riesgos. Segunda, en mercados ineficientes la integración del análisis textual es decisiva, y los modelos que ignoran el texto no pueden competir en precisión direccional. Tercera, existen estrategias capaces de generar retornos astronómicos a costa de perfiles de riesgo que rozan la ruina, por lo que la viabilidad de inversión no debe confundirse con la capacidad predictiva. Cuarta, y más importante para este trabajo, gran parte del rendimiento publicado es frágil ante el sesgo de supervivencia, el look-ahead y el sobreajuste, de modo que cualquier afirmación sobre la rentabilidad debe acompañarse de una metodología de evaluación que controle explícitamente esos sesgos.

Capítulo 3

Diseño

En este capítulo se describe el diseño del sistema híbrido desarrollado. Se parte de una visión global de la arquitectura y se detalla después la función de cada módulo, prestando especial atención a las decisiones que garantizan que la evaluación posterior sea representativa de las condiciones reales de operación.

3.1 Arquitectura general

El sistema sigue una arquitectura modular de tres niveles, ilustrada en la Figura 3.1. La separación en niveles favorece la independencia de cada componente, facilita el mantenimiento y permite sustituir módulos concretos sin afectar al resto. El primer nivel se encarga de la ingesta de datos; el segundo, del procesamiento y de los modelos; y el tercero, de un sistema multi-agente que sintetiza la información y produce una decisión final de carácter híbrido.




Figura 3.1: Arquitectura del sistema híbrido ML + LLM. Fuente: elaboración propia.

3.2 Módulo de ingesta de datos

3.2.1 Datos de mercado

Los precios históricos se obtienen mediante la librería `yfinance`, que proporciona acceso gratuito a los datos de Yahoo Finance. Para cada activo se descargan los campos OHLCV (apertura, máximo, mínimo, cierre y volumen) con frecuencia diaria y un histórico de varios años. El sistema admite distintos modos de universo: un universo de acciones individuales, un universo diversificado que combina renta variable, bonos, oro, materias primas, divisa y criptoactivos, y un universo amplio y aleatorio muestreado de una instantánea histórica del S&P 500, este último destinado al test de sesgo de supervivencia descrito en el Capítulo 5.

3.2.2 Datos de noticias

Las noticias financieras se obtienen mediante feeds RSS de fuentes gratuitas (Yahoo Finance, MarketWatch y, para criptoactivos, CoinDesk y Cointelegraph). El módulo `feedparser` parsea los feeds y extrae títulos, resúmenes y fechas de publicación, que alimentan el análisis de sentimiento.

3.2.3 LLM gratuito

Para el análisis de sentimiento y la interpretación de datos se emplea un LLM gratuito, mediante la ejecución local de modelos como Llama 3.2 o Mistral con Ollama, o mediante la API de inferencia gratuita de Hugging Face. Si no hay LLM disponible, el sistema recurre a un análisis basado en reglas, de modo que su funcionamiento nunca depende de un servicio de pago.

3.2.4 Tratamiento causal de los datos

Un requisito transversal de la ingesta es la causalidad estricta: en ningún momento del histórico puede emplearse información que no estuviera disponible en esa fecha. Por ello, el relleno de huecos en las series de precios se realiza exclusivamente hacia delante, completando los valores ausentes con el último dato conocido y descartando los valores nulos iniciales. Se evita de forma expresa el relleno hacia atrás y la interpolación bidireccional, que introducirían precios futuros en el pasado. Este criterio resulta esencial para que el backtesting posterior sea representativo.

3.3 Módulo de aprendizaje automático

3.3.1 Modelos tradicionales

Se implementan tres modelos de ensemble para la predicción de retornos: Random Forest, XGBoost y LightGBM. Para evitar la fuga de información, el escalado de las variables se ajusta únicamente con los datos de entrenamiento y se aplica después al conjunto de test, en lugar de ajustarse sobre la totalidad de la serie antes de la partición temporal. En la predicción de volatilidad se añade además un embargo en la variable objetivo, dejando un margen temporal entre entrenamiento y test que impide el solapamiento de ventanas. Sin estas precauciones, las métricas de evaluación quedan artificialmente infladas.

3.3.2 Modelo GARCH para volatilidad

El modelo GARCH(1,1) se implementa con la librería `arch` [19]. Su especificación es:

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad (3.1)$$

donde σ_t^2 es la varianza condicional, ω la varianza de largo plazo, α captura el efecto de los shocks recientes y β la persistencia de la volatilidad. La introducción del modelo GARCH responde a un hecho bien establecido en la literatura: la volatilidad presenta agrupamiento y es notablemente más predecible que los retornos [20].

3.3.3 Detección de patrones chartistas

Se implementan los patrones técnicos más habituales: doble techo y doble suelo, cabeza y hombros en su forma normal e invertida, triángulos (ascendente, descendente y simétrico) y cuñas. La detección se realiza mediante el análisis de extremos locales con `scipy.signal`.

3.4 Sistema multi-agente

El sistema multi-agente se inspira en la arquitectura de QuantAgents [4] y consta de cuatro agentes especializados. El **analista técnico** calcula indicadores como el RSI, el MACD, las bandas de Bollinger, las medias móviles y el ATR. El **analista de sentimiento** procesa las noticias reales con el LLM, calcula puntuaciones de sentimiento en el rango de menos uno a más uno y las integra con el índice de miedo y codicia. El **gestor de riesgo** calcula el VaR y el CVaR, predice la volatilidad con GARCH y determina el tamaño de la posición a partir del criterio de Kelly, fijando además los niveles de stop-loss y take-profit. Por

último, el **gestor de cartera** coordina a los demás agentes y toma la decisión final, empleando el LLM como intérprete para sintetizar los análisis individuales en una recomendación coherente.

Sobre estos agentes se implementa además un mecanismo de debate estructurado: en lugar de pedir al LLM una valoración en una sola pasada, se le obliga a articular por separado una tesis alcista y una tesis bajista, y un juez neutral pondera la convicción resultante. Una decisión de diseño importante es que el juez no altera la dirección que fija el modelo cuantitativo, sino que solo modula el tamaño de la posición. El diseño exacto de los prompts, el mecanismo de debate y la gestión de la memoria y el contexto entre agentes se detallan en el Anexo D.

3.5 Sistema híbrido ML + LLM

El sistema híbrido combina la predicción cuantitativa del aprendizaje automático con el análisis cualitativo del LLM mediante una ponderación adaptativa:

$$\text{Score}_{\text{híbrido}} = w_{ML} \cdot \text{Señal}_{ML} + w_{LLM} \cdot \text{Señal}_{LLM}, \quad (3.2)$$

donde los pesos w_{ML} y w_{LLM} se ajustan dinámicamente según la confianza de cada componente. De este modo, el LLM actúa como modulador del componente numérico y no como sustituto, lo que permite estudiar por separado la aportación de cada parte.

Capítulo 4

Desarrollo

Este capítulo describe la implementación técnica del sistema. Se detallan las tecnologías empleadas y se muestran los fragmentos de código más representativos de cada módulo.

4.1 Tecnologías utilizadas

El sistema se ha desarrollado en Python 3.9 o superior. La Tabla 4.1 recoge las librerías principales y su propósito.

Tabla 4.1: Librerías principales utilizadas. Fuente: elaboración propia.

Librería	Propósito
pandas, numpy	Manipulación de datos y cómputo numérico
scikit-learn	Aprendizaje automático y preprocesado
xgboost, lightgbm	Gradient boosting
arch	Modelos GARCH de volatilidad
yfinance	Descarga de datos financieros
feedparser	Lectura de feeds RSS de noticias
requests, beautifulsoup4	Acceso HTTP y extracción de texto
matplotlib	Visualización de resultados
scipy	Procesamiento de señales y estadística

4.2 Implementación del modelo GARCH

La implementación del modelo GARCH se apoya en la librería arch. Se opta por una distribución t de Student en lugar de una normal, ya que captura mejor las colas pesadas características de los retornos financieros.

```
from arch import arch_model

# Modelo GARCH(1,1) con distribucion t de Student
garch = arch_model(returns, vol='GARCH', p=1, q=1,
                    dist='t', rescale=False)
```

```
results = garch.fit(dispatch='off')

# Predicción de la volatilidad a 5 días
forecast = results.forecast(horizon=5)
```

4.3 Implementación del sistema multi-agente

Cada agente hereda de una clase base `BaseAgent` que proporciona la funcionalidad común, en particular la memoria del agente y la interfaz de análisis.

```
class BaseAgent(ABC):
    def __init__(self, name: str, role: str, description: str):
        self.name = name
        self.role = role
        self.description = description
        self.memory = []

    @abstractmethod
    def analyze(self, data: Dict) -> AnalysisResult:
        pass
```

La comunicación entre agentes se realiza mediante un bus de mensajes que implementa un patrón de publicación y suscripción, de modo que cada agente publica su análisis y el gestor de cartera lo recoge para tomar la decisión final. Los fragmentos anteriores son deliberadamente breves; el diseño completo de los prompts del sistema, el mecanismo de debate entre agentes, la gestión de la memoria con ventana deslizante y el tratamiento robusto de la salida del LLM se documentan en detalle en el Anexo D.

4.4 Integración con el LLM gratuito

La integración con el LLM se encapsula en una clase `LLMClient` que abstrae la interfaz con Ollama o con Hugging Face, de manera que el resto del sistema es indiferente al proveedor concreto.

```
class LLMClient:
    def __init__(self, provider: str = "ollama"):
        self.provider = provider
        self.model = "llama3.2"

    def generate(self, prompt: str, system_prompt: str = None) -> Dict:
        response = requests.post(
            "http://localhost:11434/api/generate",
            json={"model": self.model, "prompt": prompt,
                "system": system_prompt, "stream": False})
```

```
return response.json()
```

Capítulo 5

Resultados y evaluación

Este capítulo presenta la evaluación del sistema. Antes de exponer los resultados se describen las métricas empleadas y, sobre todo, el protocolo de evaluación, que constituye una de las aportaciones centrales del trabajo. La tesis del capítulo es que, en este campo, el resultado depende tanto de lo que se mide como de cómo se mide, y que una evaluación descuidada produce cifras de rentabilidad que son, en realidad, ruido.

5.1 Métricas de evaluación

Las métricas utilizadas se agrupan en cuatro familias. El **rendimiento absoluto** comprende el retorno total y el anualizado. El **riesgo** incluye la volatilidad anualizada, el drawdown máximo, el Ulcer Index y las medidas de VaR y CVaR. El **rendimiento ajustado por riesgo** reúne los ratios de Sharpe, Sortino, Calmar y Omega. Por último, las métricas de **trading** recogen el win rate, el profit factor, el payoff ratio y el criterio de Kelly.

En el cálculo de algunas de estas métricas se corrigieron definiciones erróneas detectadas en una primera implementación. El ratio de Sortino empleaba la desviación típica de los retornos negativos, que resta su propia media y descarta los días positivos, produciendo un valor arbitrario; se sustituyó por la downside deviation estándar, que penaliza únicamente los retornos por debajo del objetivo sobre el total de observaciones. El VaR mezclaba el estimador histórico y el paramétrico mediante un operador máximo no estándar, y el CVaR podía quedar por debajo del VaR, violando la definición de pérdida esperada; ambos se reformularon con el estimador empírico, garantizando la relación CVaR mayor o igual que VaR.

5.2 Protocolo de evaluación riguroso

Una primera fase del trabajo reveló que las cifras de rentabilidad iniciales estaban contaminadas por varios errores metodológicos. Antes de medir el rendimiento real fue necesario corregirlos, ya que sin ello cualquier resultado carece de valor. Las correcciones principales fueron las siguientes:

- **Fuga de información en el escalado.** El escalador se ajustaba sobre el

conjunto de entrenamiento y test conjuntamente, antes de la partición temporal. Se corrigió ajustándolo solo con los datos de entrenamiento (Sección 3.3).

- **Look-ahead en la ingesta.** El relleno hacia atrás introducía precios futuros; se substituyó por relleno solo hacia delante (Sección 3.2.4).
- **Umbral de señal no causal.** El percentil que activaba las entradas se calculaba sobre toda la distribución del periodo de test, empleando días futuros. Se corrigió a una ventana expansiva, que en cada instante solo usa información pasada.
- **Curva de equity con calendarios mixtos.** Al combinar activos con calendarios distintos (los criptoactivos cotizan en fin de semana y las acciones no), las posiciones de los símbolos sin barra ese día desaparecían del valor de cartera y reaparecían al siguiente, lo que generaba saltos fantasma de más menos 50% que inflaban el Sharpe, el Sortino y el drawdown. Se corrigió con relleno hacia delante del último cierre conocido. El efecto fue drástico: la volatilidad diaria de la curva pasó de un 25% irreal a un 1,7% coherente.
- **Backtest con señales aleatorias.** Se eliminó un método que generaba señales al azar y aplicaba retornos del día siguiente, un marcador de posición sin valor evaluativo.

Sobre esta base depurada, la evaluación adopta tres garantías adicionales. En primer lugar, para no sesgar las conclusiones a partir de una única ventana favorable, se utiliza una **cuadrícula multi-régimen**: 10 fechas de inicio entre 2018 y 2023, que cubren la fase previa a la COVID, el desplome de 2020, la recuperación, el mercado alcista de 2021, el bajista de 2022 y la recuperación de 2023, combinadas con 4 plazos de tenencia (3 meses, 6 meses, 1 año y 2 años), lo que arroja del orden de 280 backtests independientes. En segundo lugar, se incorporan **benchmarks realistas**: dado que comprar y mantener el propio universo, con criptoactivos incluidos, es una comparación injusta, se añaden el SPY (comprar y mantener el S&P 500) y una cartera 60/40, junto con las métricas de alpha relativo. En tercer lugar, se realiza un **test de sesgo de supervivencia**, repitiendo la evaluación sobre el universo amplio y aleatorio del S&P 500 en lugar de sobre las acciones famosas elegidas a posteriori.

Por último, la evaluación se acompaña de una **conciencia explícita del sobreajuste**. Dado el elevado número de configuraciones probadas, se emplea el Deflated Sharpe Ratio de Bailey y López de Prado [21] para descontar el Sharpe esperado por puro azar, evitando confundir la suerte con la habilidad.

5.3 Resultados del backtesting

5.3.1 Resultado ilustrativo en un activo

La Tabla 5.1 recoge el resultado para AAPL en el periodo 2021-2024, y la Figura 5.1 muestra la curva de equity, el drawdown y la distribución de operaciones correspondientes.

Tabla 5.1: Resultados del backtesting para AAPL (2021-2024). Fuente: elaboración propia.

Métrica	Valor
Retorno total	8,55%
Retorno anualizado	2,78%
Ratio de Sharpe	0,22
Ratio de Sortino	0,35
Ratio de Calmar	0,18
Drawdown máximo	-46,57%
Ulcer Index	0,2341
Win rate	31,6%
Profit factor	1,08
Operaciones totales	19

El rendimiento es positivo pero modesto. Un Sharpe de 0,22 queda por debajo del que el S&P 500 ha ofrecido históricamente, en torno a 0,6, y un drawdown del 46,57% es considerablemente alto, lo que sugiere que la estrategia, leída de forma aislada, necesitaría mejoras importantes en la gestión del riesgo.

5.3.2 Análisis de robustez por régimen de volatilidad

La Tabla 5.2 desglosa el rendimiento por régimen de volatilidad. La estrategia funciona mejor en régimen de baja volatilidad y sufre de forma acusada en los periodos de alta volatilidad, un comportamiento consistente con la literatura sobre estrategias de momentum [22].

5.3.3 Rendimiento por plazo de tenencia

Evaluada la variante principal del sistema, un seguimiento de tendencia multi-activo con rotación por momentum, sobre la cuadrícula completa, los resultados deben leerse distinguiendo entre media y mediana, porque divergen




Figura 5.1: Curva de equity, drawdown, métricas y distribución de operaciones para AAPL. Fuente: elaboración propia.

Tabla 5.2: Rendimiento por régimen de volatilidad. Fuente: elaboración propia.


Régimen	Sharpe	Drawdown máximo
Baja volatilidad	0,45	−12,3%
Volatilidad normal	0,18	−28,7%
Alta volatilidad	−0,32	−51,2%

de forma considerable. La Tabla 5.3 y la Figura 5.2 resumen el rendimiento por plazo frente al SPY.

La discrepancia entre media y mediana no es anecdótica. Ordenadas de menor a mayor, las 10 pruebas a 2 años fueron −26%, −22%, +12%, +20%, +22%, +29%, +147%, +239%, +371% y +537%. La media, del 132,9%, está disparada por tres o cuatro aciertos de cola en criptoactivos durante 2020 y 2021, de modo que 6 de las 10 pruebas quedaron por debajo de la media. En consecuencia, para juzgar la utilidad real del sistema debe emplearse la mediana, del 25,6% a 2 años, que refleja el resultado típico, y no la media, sesgada al alza.

Tabla 5.3: Rendimiento por plazo de tenencia (media frente a mediana) y comparación con el SPY. Fuente: elaboración propia.

Plazo	Mediana	Media	% en positivo	SPY (mediana)
3 meses	-8,7%	-13,0%	30%	+3,1%
6 meses	-6,6%	+4,9%	40%	+11,8%
1 año	+5,4%	+29,9%	60%	+15,7%
2 años	+25,6%	+132,9%	80%	+32,8%

**Figura 5.2:** Retorno mediano del sistema frente al SPY por plazo de tenencia. Fuente: elaboración propia.

5.3.4 Comparación frente a la inversión indexada pasiva

La pregunta determinante no es si el sistema gana dinero, sino si supera a la alternativa trivial de comprar y mantener un índice. La respuesta es matizada. En términos absolutos, el sistema es rentable a plazos largos: a 2 años termina en positivo el 80% de las veces. Sin embargo, frente a comprar y mantener el SPY no compensa: en el caso típico el SPY rinde igual o más (a 2 años, un 32,8% frente al 25,6% del sistema) y el sistema solo supera al SPY en el 42% de las ventanas, prácticamente un cara o cruz, asumiendo además mucho más riesgo. Ajustado por riesgo, la diferencia es nítida: el Sharpe del SPY es 0,97 frente al 0,25 del sistema, como ilustra la Figura 5.3. El índice es, aproximadamente, cuatro veces mejor por unidad de riesgo.




Figura 5.3: Ratio de Sharpe del sistema frente al SPY. Fuente: elaboración propia.

5.3.5 Palancas de mejora evaluadas

Con el objetivo de superar a la referencia se probaron de forma rigurosa varias palancas de mejora, midiendo cada una sobre la cuadrícula completa (Tabla 5.4). Ninguna mejora la rentabilidad ajustada por riesgo de la configuración base.

Tabla 5.4: Palancas de mejora y su efecto sobre el Sharpe medio. Fuente: elaboración propia.

Palanca	Sharpe medio
Configuración base (tendencia + rotación)	0,25
Universo diversificado (bonos, oro, materias primas)	−0,48
Señal TSMOM multi-horizonte	−0,38
Sizing por riesgo (inverse-vol y vol-target)	0,16
Holdings más largos (252 / 504 / sin tope)	≤ 0,07

Además, la propia configuración base está probablemente sobreajustada: el Deflated Sharpe Ratio indica que, con el número de configuraciones probadas, del orden de 50 a 100, el Sharpe esperado por puro azar es de 0,82 a 0,92, por encima del 0,25 observado. Seguir buscando configuraciones que ganen en estas ventanas sería sobreajuste, no una mejora real. El compromiso entre riesgo y rentabilidad resulta ineludible: el sizing por riesgo recorta el drawdown, del 27,9% al 23,9% a 2 años, pero reduce la media, del 132,9% al 71,3%, porque esa media elevada procede precisamente de la exposición volátil que el control de riesgo modera.

5.3.6 Test de sesgo de supervivencia

Sobre el universo amplio y aleatorio del S&P 500, en lugar de las acciones elegidas a posteriori, la estrategia pierde dinero a todos los plazos, con un retorno medio en torno al -11% y superando a comprar y mantener solo en el 8% de los casos. Este resultado confirma que buena parte del rendimiento aparente del universo reducido se debía a la selección de activos en retrospectiva, y no a una habilidad genuina del sistema.

5.3.7 Validación fuera de muestra (lockbox 2024-2025)

A partir de la mejor configuración honesta identificada, una estrategia de timing de tendencia tipo Faber [23] sobre el Nasdaq-100 (mantener QQQ mientras cotiza por encima de su media de 200 sesiones, y efectivo en caso contrario), se ejecutó una validación fuera de muestra. El protocolo se endureció en tres aspectos: muchas fechas de inicio aleatorias con semilla fija por horizonte; separación de dos universos temporales disjuntos, un periodo de desarrollo (2014-2023) y un lockbox reservado (2024-2025) evaluado una sola vez; y la incorporación de un test de causalidad automático que comprueba que mutar los precios posteriores a un instante no altera la señal en ese instante.

La única mejora robusta resultó ser de naturaleza contable. La configuración base dejaba el efectivo sin remunerar mientras estaba fuera de mercado, en torno al 20 o 30% del tiempo. Acreditar el tipo libre de riesgo sobre ese efectivo, con un retardo de un día para garantizar la causalidad, no es una apuesta de estrategia, sino contabilidad correcta. La mejora es estricta y significativa en todos los horizontes, tanto en desarrollo como en el lockbox (Tabla 5.5), sin aumentar el drawdown y sin un solo caso en que empeore.

Tabla 5.5: Efecto de la remuneración del efectivo (variación de retorno frente a la base, IC 95%). Fuente: elaboración propia.

Plazo	Desarrollo 2014-2023	Lockbox 2024-2025
6 meses	+0,15 [+0,06, +0,26]	+0,36 [+0,23, +0,48]
1 año	+0,34 [+0,15, +0,58]	+0,68 [+0,57, +0,79]
2 años	+0,59 [+0,37, +0,82]	+1,12 [+1,07, +1,17]

Frente a los benchmarks (Figura 5.4), la estrategia con efectivo remunerado bate de forma robusta a la cartera 60/40, con un alpha de 7,99 puntos a 1 año y de 19,34 puntos a 2 años, superándola en el 100% de las ventanas y con un drawdown medio en torno al -13% . Frente al SPY empata o lo supera ligeramente, con un alpha de 0,61 y 0,78 puntos a 1 y 2 años, y menor drawdown. El matiz honesto es doble: frente al 60/40 esta ventaja es sobre todo beta de crecimiento más un filtro de caídas, no alpha; y la estrategia sigue sin batir a su propio

subyacente en un mercado alcista, algo estructuralmente inevitable para una estrategia que solo puede estar comprada o en efectivo, cuyo valor es esquivar el drawdown en los mercados bajistas.




Figura 5.4: Alpha de la estrategia Faber-XXX con efectivo remunerado frente a la cartera 60/40 y al SPY (lockbox, fuera de muestra). Fuente: elaboración propia.

Por último, el aprendizaje automático y el LLM aplicados de forma correcta tampoco generan ventaja. Siguiendo a López de Prado [24], se aplicó meta-labeling sobre la señal primaria, con etiquetado por triple barrera, validación mediante Purged K-Fold con embargo y ponderación por unicidad, empleado solo para reducir o vetar el tamaño de la posición. El resultado fuera de fold es un nulo rotundo, con un AUC de 0,385, por debajo del azar. Un test análogo del LLM local como meta-filtro arroja igualmente un nulo, con un AUC de 0,460 y un claro sesgo de optimismo. Ni el componente aprendido ni el LLM añaden información accionable para seleccionar o dimensionar las entradas.

5.4 Discusión de resultados

Los resultados confirman varios hallazgos de la literatura. La predicción de retornos exactos es extremadamente difícil, con modelos que muestran un coeficiente de determinación negativo, lo que es coherente con la hipótesis de los mercados eficientes en forma semifuerte [1]. La volatilidad, en cambio, es más predecible, y el modelo GARCH ofrece estimaciones útiles [20]. El análisis de sentimiento mediante LLM aporta información adicional en determinados episodios de mercado, pero no de forma sistemática.

El hallazgo central es la ausencia de alpha sostenible ajustado por riesgo. Una vez eliminados los sesgos metodológicos y evaluado el sistema sobre la cuadrícula multi-régimen y un universo sin sesgo de supervivencia, la sofisticación añadida

(el aprendizaje automático, el LLM y la arquitectura multi-agente) no se traduce en una ventaja sobre la inversión indexada pasiva en términos ajustados por riesgo. La validación posterior en el lockbox refuerza este hallazgo desde otro ángulo: la única mejora robusta es de naturaleza contable, mientras que el aprendizaje automático y el LLM resultan nulos fuera de muestra. La utilidad defendible del sistema se sitúa, por tanto, en la gestión del riesgo, una exposición a crecimiento con filtro de caídas que bate a la cartera 60/40 y empata al SPY con menor drawdown, antes que en la generación de alpha.

Capítulo 6

Conclusiones y trabajo futuro

El objetivo de este Trabajo Fin de Grado ha sido diseñar, implementar y, sobre todo, evaluar con honestidad un sistema híbrido para la predicción financiera que combina aprendizaje automático, un modelo GARCH de volatilidad y un sistema multi-agente apoyado en un LLM gratuito. A continuación se recogen las conclusiones, las limitaciones detectadas y las líneas de trabajo futuro.

6.1 Conclusiones

El trabajo ha producido un sistema completo y funcional de extremo a extremo, que va desde la ingesta de datos reales hasta una interfaz de visualización, pasando por los modelos, el sistema multi-agente, la gestión de riesgo y el backtesting. Las conclusiones principales son las siguientes:

- La predicción de retornos exactos es extremadamente difícil. Los modelos de aprendizaje automático muestran un coeficiente de determinación negativo, lo que es coherente con la hipótesis de los mercados eficientes.
- La volatilidad es más predecible que los retornos, y el modelo GARCH proporciona estimaciones útiles para la gestión del riesgo.
- Una vez corregidos los sesgos metodológicos, el sistema gana dinero en términos absolutos a plazos largos (positivo en el 80% de las ventanas a 2 años, con un 25,6% típico), pero no bate al indexado pasivo ajustando por riesgo (Sharpe de 0,25 frente al 0,97 del SPY) y solo supera al SPY en el 42% de las ventanas.
- En un universo realista sin sesgo de supervivencia el sistema deja de ser rentable, lo que confirma que parte del rendimiento aparente procedía de la selección de activos en retrospectiva.
- La validación fuera de muestra en el lockbox 2024-2025 ofrece una conclusión matizada y constructiva: la única mejora robusta es de naturaleza contable (remunerar el efectivo ocioso), mientras que aplicar el aprendizaje automático de forma correcta y el LLM como meta-filtro resultan nulos. El valor del enfoque reside en la gestión del riesgo y no en una ventaja predictiva.

Este resultado es coherente con la hipótesis del mercado eficiente y con la literatura: un sistema técnico que opera sobre datos diarios no obtiene una

ventaja estructural sostenible en estos activos. Lejos de constituir un fracaso, se trata de un resultado válido y defendible. El valor del trabajo reside en tres elementos: un sistema completo y funcional, una metodología de evaluación rigurosa sin look-ahead, con test de sesgo de supervivencia, benchmarks justos y conciencia del sobreajuste, y un hallazgo honesto, a saber, que la sofisticación no se traduce en α sobre el indexado pasivo en términos ajustados por riesgo.

6.2 Limitaciones

El trabajo presenta varias limitaciones. El análisis emplea datos diarios de Yahoo Finance, sin información intradía ni fuentes alternativas que pudieran aportar señales adicionales. Los costes de transacción se modelan de forma simplificada, sin considerar el deslizamiento real ni el impacto de mercado. El sistema depende, para el análisis cualitativo, de un LLM ejecutándose localmente, lo que puede no ser práctico para todos los usuarios. Por último, el universo de activos sigue siendo limitado y el Deflated Sharpe Ratio sugiere que el rendimiento de la configuración base es indistinguible del esperado por azar dado el número de configuraciones exploradas.

6.3 Trabajo futuro

A partir de lo anterior se proponen varias líneas de trabajo futuro. La primera es extender la práctica del lockbox temporal a otros subyacentes e índices conforme avance el calendario, manteniendo periodos reservados y evaluados una sola vez. La segunda es calcular de forma sistemática la probabilidad de sobreajuste mediante validación cruzada combinatoria purgada para cada mejora candidata, antes de darla por buena. La tercera, respaldada por la evidencia del lockbox, es formalizar el sistema como herramienta de gestión del riesgo, con superposiciones de control de drawdown y de volatilidad y un marco de asignación tipo risk parity, validados siempre fuera de muestra. Además, sería de interés evaluar LLMs más potentes, ampliar el catálogo de patrones chartistas a formaciones más complejas, optimizar los hiperparámetros de los modelos con herramientas específicas y llevar el sistema a un entorno de paper trading en tiempo real.

Capítulo 7

Análisis de impacto

En este capítulo se analiza el impacto potencial de los resultados obtenidos en distintos ámbitos, así como la relación del trabajo con los Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030. Conviene precisar desde el principio que el principal impacto de este trabajo no es un sistema que bata al mercado, sino una contribución metodológica: mostrar cómo evaluar de forma honesta la capacidad predictiva de la inteligencia artificial en finanzas y cómo comunicar sus límites sin exagerarlos.

7.1 Impacto personal

Desde un punto de vista personal, este proyecto ha supuesto un avance importante en mi formación. Me ha permitido integrar conocimientos de estadística, aprendizaje automático, ingeniería de software y finanzas cuantitativas en un único sistema, y ha reforzado una idea que considero la lección más valiosa del trabajo: en ciencia de datos, la integridad metodológica vale más que un resultado vistoso. Aprender a desconfiar de las cifras propias, a buscar de forma activa los sesgos que las inflan y a aceptar un resultado honesto aunque sea menos espectacular, es una competencia profesional que trasciende este proyecto concreto.

7.2 Impacto económico y empresarial

En el plano económico, el trabajo tiene un valor sobre todo preventivo. La industria de la gestión de activos y el creciente sector de las aplicaciones de inversión para particulares promocionan con frecuencia sistemas basados en inteligencia artificial que prometen rendimientos superiores. Este trabajo muestra, con una metodología replicable, que buena parte de esas promesas no resiste una evaluación rigurosa, y que la sofisticación técnica no implica por sí misma una ventaja económica. Para una empresa, este tipo de análisis ayuda a evitar inversiones costosas en modelos que, una vez controlados los sesgos, no aportan valor frente a alternativas mucho más baratas como la inversión indexada.

Al mismo tiempo, el trabajo se ha construido íntegramente sobre herramientas y datos gratuitos y de código abierto, lo que reduce las barreras de entrada al

análisis cuantitativo y demuestra que es posible realizar investigación financiera seria sin infraestructuras costosas.

7.3 Impacto social y ético

El impacto social del trabajo es, ante todo, el de la honestidad en la comunicación. La difusión de sistemas de trading basados en inteligencia artificial que exhiben resultados inflados puede inducir a inversores particulares a asumir riesgos que no comprenden. Al documentar de forma transparente cómo unos resultados aparentemente brillantes se desvanecen al corregir los sesgos, este trabajo contribuye a una cultura de mayor alfabetización financiera y de escepticismo saludable.

No obstante, el propio sistema plantea dilemas éticos que conviene reconocer. La automatización de las decisiones de inversión puede amplificar comportamientos de rebaño si muchos agentes operan con señales similares, lo que podría afectar a la estabilidad del mercado. Además, presentar una herramienta de este tipo como infalible sería irresponsable. Por ello, en este trabajo se ha optado de forma deliberada por subrayar los límites del sistema y por enmarcarlo como apoyo a la decisión y a la gestión del riesgo, nunca como un sustituto del criterio humano.

7.4 Impacto medioambiental

El entrenamiento y la ejecución de modelos de aprendizaje automático y, en especial, de modelos de lenguaje, conllevan un consumo energético que no es despreciable. Una de las decisiones de diseño del trabajo, el uso de un LLM gratuito y ejecutable en local de tamaño reducido, así como de modelos clásicos poco costosos, responde también a un criterio de eficiencia: obtener el análisis necesario con la menor huella computacional posible, en lugar de recurrir a modelos masivos cuyo coste energético sería difícil de justificar para la ganancia marginal observada. El propio hallazgo del trabajo, que la sofisticación no añade valor predictivo, tiene una lectura medioambiental: dedicar grandes recursos de cómputo a perseguir un α que no existe es un derroche evitable.

7.5 Alineación con los Objetivos de Desarrollo Sostenible

Aunque el alcance del proyecto es académico, el trabajo se puede relacionar con varios de los Objetivos de Desarrollo Sostenible de la Agenda 2030 [25], en concreto:

- **ODS 4. Educación de calidad.** El trabajo constituye un material didáctico sobre la evaluación rigurosa de modelos predictivos y sobre los sesgos metodológicos más habituales (fuga de información, look-ahead, sesgo de supervivencia y sobreajuste), útil para la formación en ciencia de datos y en finanzas cuantitativas.
- **ODS 8. Trabajo decente y crecimiento económico.** Al promover una evaluación honesta de las tecnologías financieras, el trabajo contribuye a un crecimiento económico basado en información veraz y a la protección del pequeño inversor frente a promesas infundadas.
- **ODS 9. Industria, innovación e infraestructura.** El sistema aporta una arquitectura modular e innovadora construida con recursos abiertos, y una metodología de evaluación que puede reutilizarse en otros dominios de la inteligencia artificial aplicada.
- **ODS 12. Producción y consumo responsables.** El trabajo defiende un uso responsable de los recursos de cómputo y una comunicación responsable de los resultados, evitando el derroche energético asociado a la búsqueda de un rendimiento que la evidencia no respalda.

En este contexto, se subraya la necesidad de que tanto las organizaciones públicas como las privadas inviertan en investigación rigurosa y reproducible en inteligencia artificial, como condición para que estas tecnologías generen un beneficio social real y no una mera apariencia de innovación.

Bibliografía

- [1] E. F. Fama, “Efficient Capital Markets: A Review of Theory and Empirical Work,” *The Journal of Finance*, vol. 25, no. 2, pp. 383–417, 1970.
- [2] A. W. Lo, “Reconciling Efficient Markets with Behavioral Finance: The Adaptive Markets Hypothesis,” *Journal of Investment Consulting*, vol. 7, no. 2, pp. 21–44, 2005.
- [3] W. Fu, “The New Quant: A Survey of Large Language Models in Financial Prediction and Trading,” *arXiv preprint*, 2025.
- [4] X. Li, Y. Zeng, X. Xing, J. Xu, and X. Xu, “QuantAgents: Towards Multi-agent Financial System via Simulated Trading,” in *Proc. of EMNLP*, 2025.
- [5] X. Li, Y. Zeng, X. Xing, J. Xu, and X. Xu, “HedgeAgents: A Balanced-aware Multi-agent Financial Trading System,” in *Proc. of The Web Conference (WWW)*, 2025.
- [6] B. N. Oreshkin, D. Carпов, N. Chapados, and Y. Bengio, “N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting,” in *Proc. of ICLR*, 2020.
- [7] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, “A Time Series is Worth 64 Words: Long-term Forecasting with Transformers,” in *Proc. of ICLR*, 2023.
- [8] Y. Li et al., “Prompting Large Language Models for Zero-Shot Domain Adaptation in Sentiment Analysis,” in *Proc. of ACL*, 2024.
- [9] B. Lim, S. O. Arik, N. Loeff, and T. Pfister, “Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting,” *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021.
- [10] Z. Wang, B. Huang, S. Tu, K. Zhang, and L. Xu, “DeepTrader: A Deep Reinforcement Learning Approach for Risk-Return Balanced Portfolio Management,” in *Proc. of AAAI*, 2021.
- [11] J. Gao et al., “AlphaMix+: A Mixture-of-Experts Approach for Reinforcement Learning in Quantitative Trading,” in *Proc. of NeurIPS*, 2022.
- [12] S. Mohammadi Dashtaki et al., “HSIF: A Transformer-Based Cross-Attention Framework for Cryptocurrency Trend Forecasting via Multimodal Sentiment-Market Fusion,” *IEEE Access*, 2024.

- [13] S. Celik, “Predicting Cryptocurrency Returns: An Integrated Dataset Approach for Short-Term Forecasting,” Master’s Thesis, Aalto University, 2025.
- [14] W. W. Li, H. Kim, M. Cucuringu, and T. Ma, “Can LLM-based Financial Investing Strategies Outperform the Market in the Long Run?,” in *Proc. of KDD*, 2026.
- [15] J. Shi and B. Hollifield, “Predictive Power of LLMs in Financial Markets,” *arXiv preprint*, 2024.
- [16] J. García, “Tecnología Criptográfica y Negociación Organizada de Criptoactivos,” Trabajo Fin de Grado, Universidad Pontificia Comillas, 2024.
- [17] D. Cano Alvira, “Predicción de series temporales con modelos de IA,” Proyecto Fin de Máster, Structuralia, 2024.
- [18] L. Fernández, “IA Explicable: Programación Probabilística con PyMC para la Prevención del Blanqueo de Capitales,” Trabajo Fin de Máster, Universidad Autónoma de Madrid, 2024.
- [19] K. Sheppard, “arch: ARCH models in Python,” biblioteca de software, 2023. [Online]. Available: <https://github.com/bashtage/arch>
- [20] R. F. Engle, “Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation,” *Econometrica*, vol. 50, no. 4, pp. 987–1007, 1982.
- [21] D. H. Bailey and M. López de Prado, “The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality,” *The Journal of Portfolio Management*, vol. 40, no. 5, pp. 94–107, 2014.
- [22] C. S. Asness, T. J. Moskowitz, and L. H. Pedersen, “Value and Momentum Everywhere,” *The Journal of Finance*, vol. 68, no. 3, pp. 929–985, 2013.
- [23] M. T. Faber, “A Quantitative Approach to Tactical Asset Allocation,” *The Journal of Wealth Management*, vol. 9, no. 4, pp. 69–79, 2007.
- [24] M. López de Prado, *Advances in Financial Machine Learning*. Hoboken, NJ: Wiley, 2018.
- [25] Naciones Unidas, “Objetivos de Desarrollo Sostenible,” Agenda 2030, 2025. [Online]. Available: <https://www.un.org/sustainabledevelopment/es/objetivos-de-desarrollo-sostenible/>

Anexo A

Instalación y ejecución del sistema

A continuación se recogen los pasos para instalar y ejecutar el sistema en un entorno Unix.

```
# Clonar el repositorio
git clone <repositorio>
cd tfg_finance_ai

# Crear el entorno virtual e instalar dependencias
python -m venv venv
source venv/bin/activate
pip install -r requirements.txt

# Instalar Ollama (opcional, para el LLM local)
curl -fsSL https://ollama.com/install.sh | sh
ollama pull llama3.2

# Ejecutar el sistema
python main.py
```

Anexo B

Estructura del proyecto

El siguiente árbol resume la organización de los módulos principales del proyecto.

```
tfg_finance_ai/  
  data/ # Ingesta de datos  
    data_loader.py # Yahoo Finance  
    news_fetcher.py # Feeds RSS de noticias  
    universe_lists.py # Definicion de universos de activos  
  models/  
    ml_models/ # RF, XGBoost, LightGBM, GARCH, deep learning  
    pattern_detection/ # Patrones chartistas  
  agents/  
    technical_agent/ # Analisis tecnico  
    sentiment_agent/ # LLM + noticias reales  
    risk_agent/ # GARCH + VaR/CVaR  
    manager_agent/ # LLM interprete  
  hybrid_system/ # Combinacion ML + LLM  
  evaluation/  
    backtest.py # Metricas economicas y robustez  
  utils/ # Cache de precios/noticias, cliente LLM  
  frontend/ # Interfaz web de visualizacion  
  main.py  
  requirements.txt
```

Anexo C

Definición de las métricas económicas

Se recogen las definiciones de las principales métricas de rendimiento ajustado por riesgo empleadas en la evaluación.

$$\text{Sharpe} = \frac{R_p - R_f}{\sigma_p}, \quad \text{Sortino} = \frac{R_p - R_f}{\sigma_d}, \quad (\text{C.1})$$

$$\text{Calmar} = \frac{R_{\text{anualizado}}}{|\text{MDD}|}, \quad \text{Ulcer Index} = \sqrt{\frac{1}{N} \sum_{i=1}^N D_i^2}, \quad (\text{C.2})$$

donde R_p es el retorno de la cartera, R_f el tipo libre de riesgo, σ_p la volatilidad, σ_d la downside deviation, MDD el drawdown máximo y D_i el drawdown en el periodo i .

Anexo D

Diseño de prompts y gestión de contexto en el sistema multi-agente

Este anexo detalla, a nivel de implementación, dos aspectos que en el cuerpo de la memoria solo se describen de forma resumida: cómo gestionan los agentes su memoria y su contexto, y cómo se diseñan los prompts que recibe el LLM. El objetivo es documentar el funcionamiento interno del sistema multi-agente con el detalle que corresponde a un trabajo de Ingeniería Informática.

D.1 Gestión de la memoria y el contexto de los agentes

Todos los agentes heredan de la clase `BaseAgent`, que mantiene una memoria acotada. Cada entrada se almacena con su marca temporal y existe un tope, `max_memory_size`, fijado en 100 elementos; cuando se supera, se conservan únicamente las entradas más recientes, lo que implementa una ventana deslizante que evita un crecimiento ilimitado del contexto. El método `get_memory(n)` devuelve las `n` entradas más recientes (10 por defecto), y `get_context()` construye el encabezado de rol que se inyecta en los prompts a partir del nombre, el rol y la descripción del agente.

```
class BaseAgent(ABC):
    def __init__(self, name, role, description=""):
        self.memory = []
        self.message_queue = []
        self.max_memory_size = 100

    def add_to_memory(self, item):
        self.memory.append({'timestamp': datetime.now(), 'data': item})
        if len(self.memory) > self.max_memory_size:
            self.memory = self.memory[-self.max_memory_size:] # ventana deslizante

    def get_memory(self, n_recent=10):
        return self.memory[-n_recent:]

    def get_context(self):
        return (f"Eres {self.name}, un agente especializado en {self.role}.\n"
                f"{self.description}\n\n"
                "Tu objetivo es analizar la informacion proporcionada "
                "y ofrecer insights valiosos.")
```

La comunicación entre agentes no se apoya en una memoria compartida, sino en el paso de mensajes. Un objeto `AgentMessage` (emisor, receptor, tipo, contenido y marca temporal) viaja a través de un `AgentCommunicationBus` que registra a los agentes, entrega los mensajes punto a punto o por difusión (*broadcast*) y guarda el historial completo. Este diseño desacopla a los agentes entre sí y permite reconstruir la traza de decisiones, algo importante para auditar por qué el sistema tomó una posición concreta.

D.2 Prompt del análisis de sentimiento

El analista de sentimiento delega en el cliente LLM, que fija un prompt de sistema con un rol de analista financiero sénior y un conjunto de reglas estrictas de calibración. El prompt obliga a devolver únicamente JSON, acota la puntuación al intervalo de menos uno a más uno, exige ser conservador con las puntuaciones extremas y, sobre todo, penaliza la sobreconfianza: si la noticia es genérica, antigua o irrelevante, la confianza debe ser baja. La llamada se realiza con una temperatura baja (0,2) para favorecer respuestas deterministas.

```
system_prompt = (
    "You are a senior financial market analyst specializing in sentiment "
    "analysis for investment decisions.\n\n"
    "CRITICAL RULES:\n"
    "1. Output ONLY valid JSON - no markdown, no explanation outside the JSON.\n"
    "2. 'score' MUST be a float between -1.0 (bearish) and 1.0 (bullish).\n"
    "3. Be conservative: extreme scores (|score|>0.7) only for decisive news.\n"
    "6. 'confidence' must reflect actual certainty: generic or aged news => <=0.35. "
    "A well-calibrated 0.25 is better than a fake 0.70.\n"
    "7. Mostly noise (ads, generic recaps) => sentiment='neutral', score=0.0, "
    "confidence<=0.20.\n\n"
    'Required JSON: {"sentiment":"bullish|bearish|neutral","score":<float>,'
    '"confidence":<float>,"reasoning":"<max 60 words>"}'
)
```

La penalización explícita de la sobreconfianza, resumida en la idea de que una confianza bien calibrada de 0,25 es preferible a un 0,70 falso, es coherente con el hallazgo del Capítulo 5: el LLM tiende al optimismo y debe forzarse a calibrar su certeza.

D.3 Debate estructurado bull/bear/juez

Para reducir el ruido del LLM en una sola pasada, la valoración cualitativa de una operación se estructura en tres llamadas sucesivas. En la primera, el modelo argumenta de forma aislada la tesis alcista; en la segunda, la tesis bajista; y en la tercera, un juez neutral pondera ambas. El juez no decide la dirección de la operación, que la fija el modelo cuantitativo, sino que emite únicamente un

multiplicador de tamaño en el intervalo de 0,3 a 1,0 que modula la posición calculada por el criterio de Kelly. Si ese multiplicador cae por debajo de un umbral, la operación puede tratarse como vetada y mantenerse en liquidez. Cada pasada utiliza el mismo prompt de sistema, que obliga a producir solo JSON, y temperaturas bajas (0,3 para las tesis y 0,2 para el juez). El coste es de tres llamadas por decisión, amortizado por la caché trimestral del backtesting.

```
def build_bull_prompt(ml_pred, technical, sentiment, risk):
    return (
        "You are a strict BULLISH equity/crypto analyst. "
        "Argue the strongest LONG case.\n\n"
        f"TECHNICAL: {technical}\nSENTIMENT: {sentiment}\n"
        f"RISK: {risk}\nML PREDICTION: {ml_pred}\n\n"
        "Provide exactly 3 concrete bullet points supporting a LONG entry.\n"
        "Be terse, factual. No hedging.\n"
        "Return ONLY a single JSON object on one line:\n"
        '{"bull_args": ["point 1", "point 2", "point 3"]}')

def build_judge_prompt(ml_pred, bull_args, bear_args, sentiment, risk):
    return (
        "You are a NEUTRAL JUDGE evaluating a trade decision.\n\n"
        "ML decides DIRECTION; your role is to output a SIZING "
        "multiplier in [0.3, 1.0].\n\n"
        f"ML PREDICTION: {ml_pred}\nSENTIMENT: {sentiment}\nRISK: {risk}\n\n"
        "BULL CASE:\n" + bull_block + "\n\nBEAR CASE:\n" + bear_block + "\n\n"
        "1.0 -> bull case clearly dominates (full size)\n"
        "0.5 -> balanced, both sides valid (50% size)\n"
        "0.3 -> bear case dominates (30% size)\n\n"
        "Do NOT flip direction. Only modulate sizing.\n"
        'Return ONLY a single JSON object: {"confidence": 0.X}')
```

La decisión de diseño clave es que el LLM nunca invierte la dirección del modelo cuantitativo: solo modula la convicción. Esto preserva al modelo de aprendizaje automático como decisor primario y acota el daño que podría causar una alucinación del LLM. Esta cautela resultó acertada a la luz de los resultados: como se expone en la Sección 5.3.7, el LLM empleado como meta-filtro de las entradas resulta nulo fuera de muestra, con un área bajo la curva de 0,460.

D.4 Tratamiento robusto de la salida del LLM

Los modelos de lenguaje pequeños no siempre devuelven JSON limpio, por lo que la extracción de la respuesta se realiza en tres niveles. Primero se intenta interpretar el texto completo como JSON. Si falla, se busca el primer objeto delimitado por llaves equilibradas recorriendo el texto carácter a carácter. Y, como último recurso, se vuelve a interrogar al modelo con una instrucción estricta, a temperatura 0,1, pidiéndole únicamente el objeto JSON con las claves requeridas. Si todo falla, el sistema recurre a un análisis basado en reglas, de

modo que su funcionamiento nunca depende de que el LLM acierte el formato de salida.

```
# Ultimo recurso: re-prompt estricto si no se pudo parsear el JSON
strict_prompt = (
    "Your previous response could not be parsed as JSON. "
    "Respond ONLY with a valid JSON object - no explanation, no markdown, "
    "no code blocks. Just the raw JSON object.\n\n"
    f"Required keys: {required_keys}\n\nOriginal response:\n{text}")
retry = self._generate_ollama(strict_prompt, system_prompt,
                              temperature=0.1, max_tokens=512)
```